



Advanced Computer Science Course Lecture 1

Tishreen University


Computer and automatic control
engineering dept.

Master Program- 2024

1st year

Dr. Ali Mahmoud Mayya

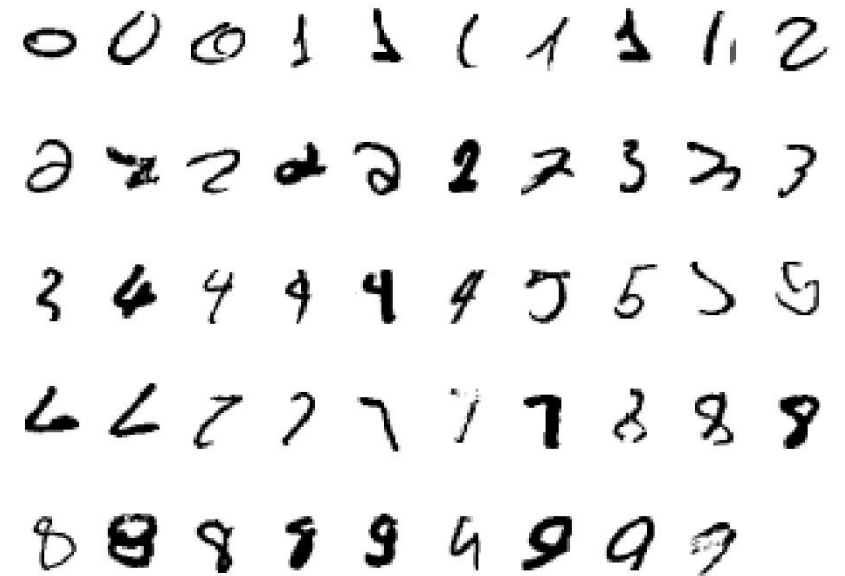
Deep Learning Vs. Machine Learning



Machine Learning

- **Supervised learning** (training with labeled data), **unsupervised learning** (clustering un-labeled data), and **semi-supervised learning** (use both labeled and unlabeled data)
- Supervised learning: **classification** and **regression**
- **Classification**: output is discrete value
- **Regression**: output is real value

Learning Example: Recognize Handwriting




Classification: recognize each number

Clustering: cluster the same numbers together

Regression: predict the index of Dow-Jones

Machine Learning- Linear regression

Statistics Root: Linear Regression Example



DATASET

inputs	outputs
$x_1 = 1$	$y_1 = 1$
$x_2 = 3$	$y_2 = 2.2$
$x_3 = 2$	$y_3 = 2$
$x_4 = 1.5$	$y_4 = 1.9$
$x_5 = 4$	$y_5 = 3.1$

Fish length vs. weight?

X : input or predictor

Y : output or response

Goal: learn a linear function $E[y|x] = wx + b$.

Machine Learning- Linear regression

- Definition of a linear model:

$$y = wx + b + \text{noise}.$$

$$\text{noise} \sim N(0, \sigma^2)$$

- Assume σ is a **constant**.


$$y \sim N(wx + b, \sigma^2)$$

- Estimate expected value of y given x ($E[y/x] = wx + b$).

- Given a set of data:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- Goal: to find the optimal parameters w and b .



Fish length vs. weight?


**Objective Function
(Least squared error)**

$$\sum_{i=1}^N (y_i - wx_i - b)^2$$

Machine Learning- Overfitting

The training data contains information about the regularities in the mapping from input to output. But it also contains noise. When we fit the model, it cannot tell which regularities are real and which are caused by sampling error.

So it fits both kinds of regularity.



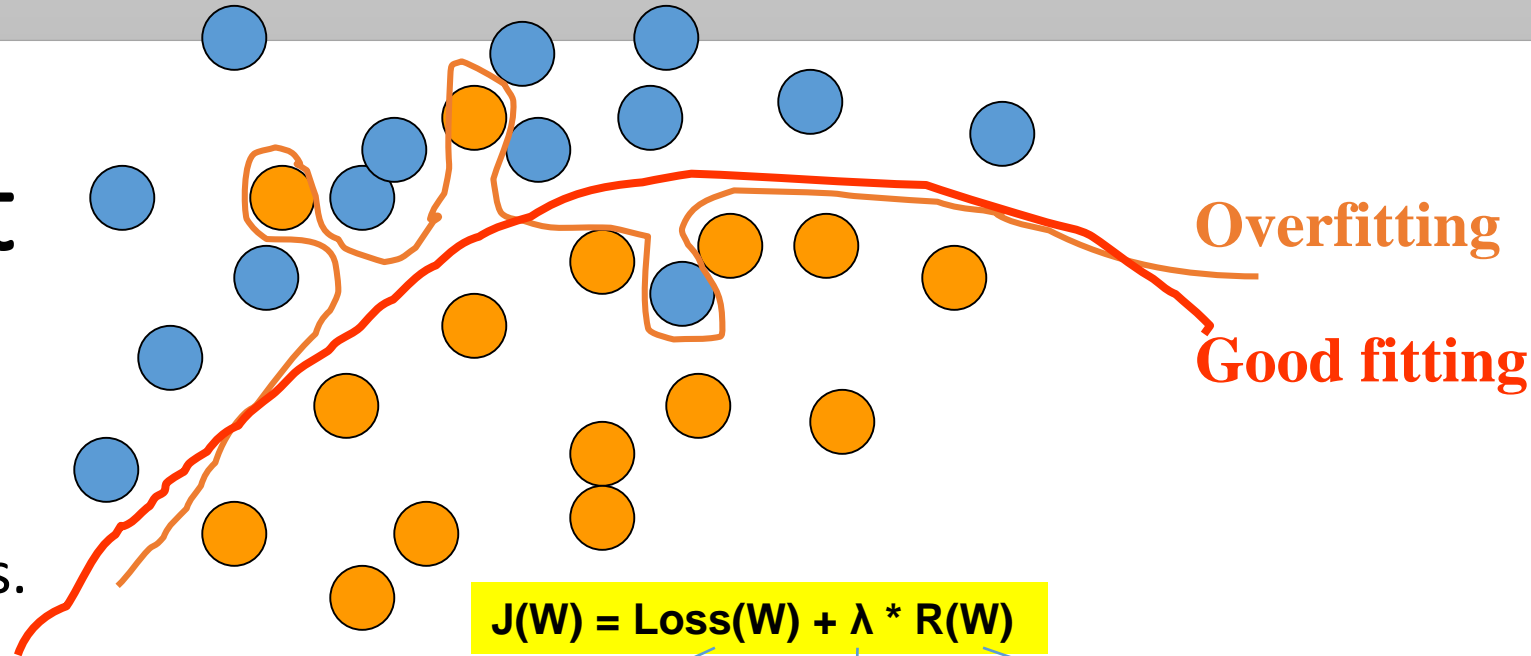
Machine Learning- Prevent Overfitting

Standard ways to limit the capacity of a neural net:

1. Limit the number of hidden units.
Limit the size of the weights (Weight-decay).

Adding a **penalty** term to the cost function during training. This penalty term encourages the model to have smaller weights.

2. Stop the learning before it has time to overfit (early stop training).



$$J(W) = \text{Loss}(W) + \lambda * R(W)$$

loss
function

regularization
parameter

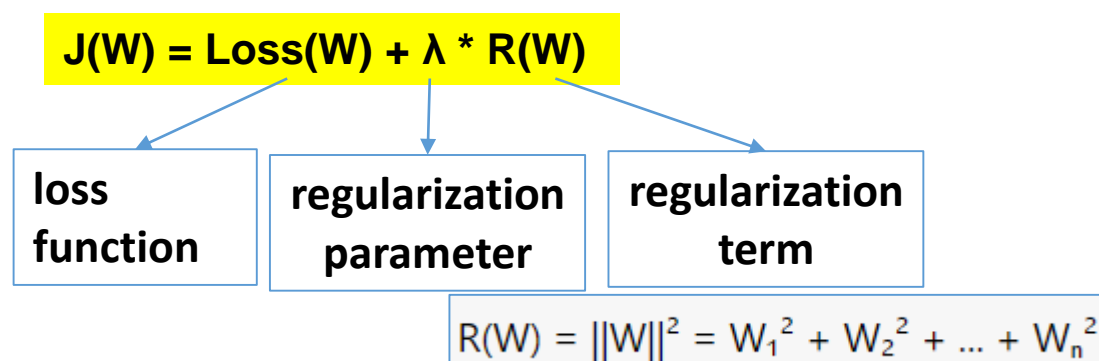
regularization
term

$$R(W) = ||W||^2 = W_1^2 + W_2^2 + \dots + W_n^2$$

The regularization parameter λ determines the relative importance of the weight decay penalty compared to the loss function. Higher values of λ increase the penalty for large weights, leading to more weight shrinkage and stronger regularization.

Machine Learning- Prevent Overfitting (training loop)

```
model = tf.keras.models.Sequential([
    tf.keras.layers.Dense(64, activation='relu',
input_shape=(input_size,)),
    tf.keras.layers.Dense(64, activation='relu'),
    tf.keras.layers.Dense(num_classes, activation='softmax')
])
# Define loss function
loss_fn = tf.keras.losses.CategoricalCrossentropy()
# Define optimizer
optimizer = tf.keras.optimizers.Adam(learning_rate=0.001)
# Define the regularization parameter (lambda)
l2_lambda = 0.01
# Define the training loop
for epoch in range(num_epochs):
    for x_batch, y_batch in train_dataset:
        with tf.GradientTape() as tape:
            # Forward pass
            logits = model(x_batch)
            # Calculate the loss
            loss_value = loss_fn(y_batch, logits)
# Calculate the weight decay penalty
l2_regularization = tf.reduce_sum([
    tf.nn.l2_loss(var) for var in model.trainable_variables])
weight_decay_penalty = l2_lambda * l2_regularization
# Add the weight decay penalty to the loss
total_loss = loss_value + weight_decay_penalty
# Compute the gradients
grads = tape.gradient(total_loss,
model.trainable_variables)
# Update the model's weights
optimizer.apply_gradients(zip(grads,
model.trainable_variables))
```



Machine Learning- Prevent Overfitting (Fit function)

```
import tensorflow as tf

# Define model architecture
model = tf.keras.models.Sequential([
    tf.keras.layers.Dense(64, activation='relu',
input_shape=(input_size,)),
    tf.keras.layers.Dense(64, activation='relu'),
    tf.keras.layers.Dense(num_classes,
activation='softmax')
])

# Define loss function
loss_fn =
tf.keras.losses.CategoricalCrossentropy()

# Define optimizer with weight decay
optimizer = tf.keras.optimizers.Adam(
    learning_rate=0.001,
    beta_1=0.9,
    beta_2=0.999,
    epsilon=1e-07,
    decay=1e-5, # Weight decay parameter
)
```

Compile the model

```
model.compile(optimizer=optimizer, loss=loss_fn,
metrics=['accuracy'])
```

Define early stopping callback

```
early_stopping = tf.keras.callbacks.EarlyStopping(
    monitor='val_loss',
    patience=3,
    restore_best_weights=True,
)
```

Train the model using model.fit

```
history = model.fit(
    x=train_data,
    y=train_labels,
    batch_size=batch_size,
    epochs=num_epochs,
    validation_data=(val_data, val_labels),
    callbacks=[early_stopping],
)
```

Evaluate the model on the test set

```
test_loss, test_accuracy = model.evaluate(x=test_data, y=test_labels)
```

Machine Learning- Prevent Overfitting- Use validation set

Divide the total dataset into three subsets:

Training data is used for learning the parameters of the model.


Validation data is not used of learning but is used for deciding what type of model and what amount of regularization works best.

Test data is used to get a final, unbiased estimate of how well the network works. We expect this estimate to be worse than on the validation data.

We could then re-divide the total dataset to get another unbiased estimate of the true error rate.

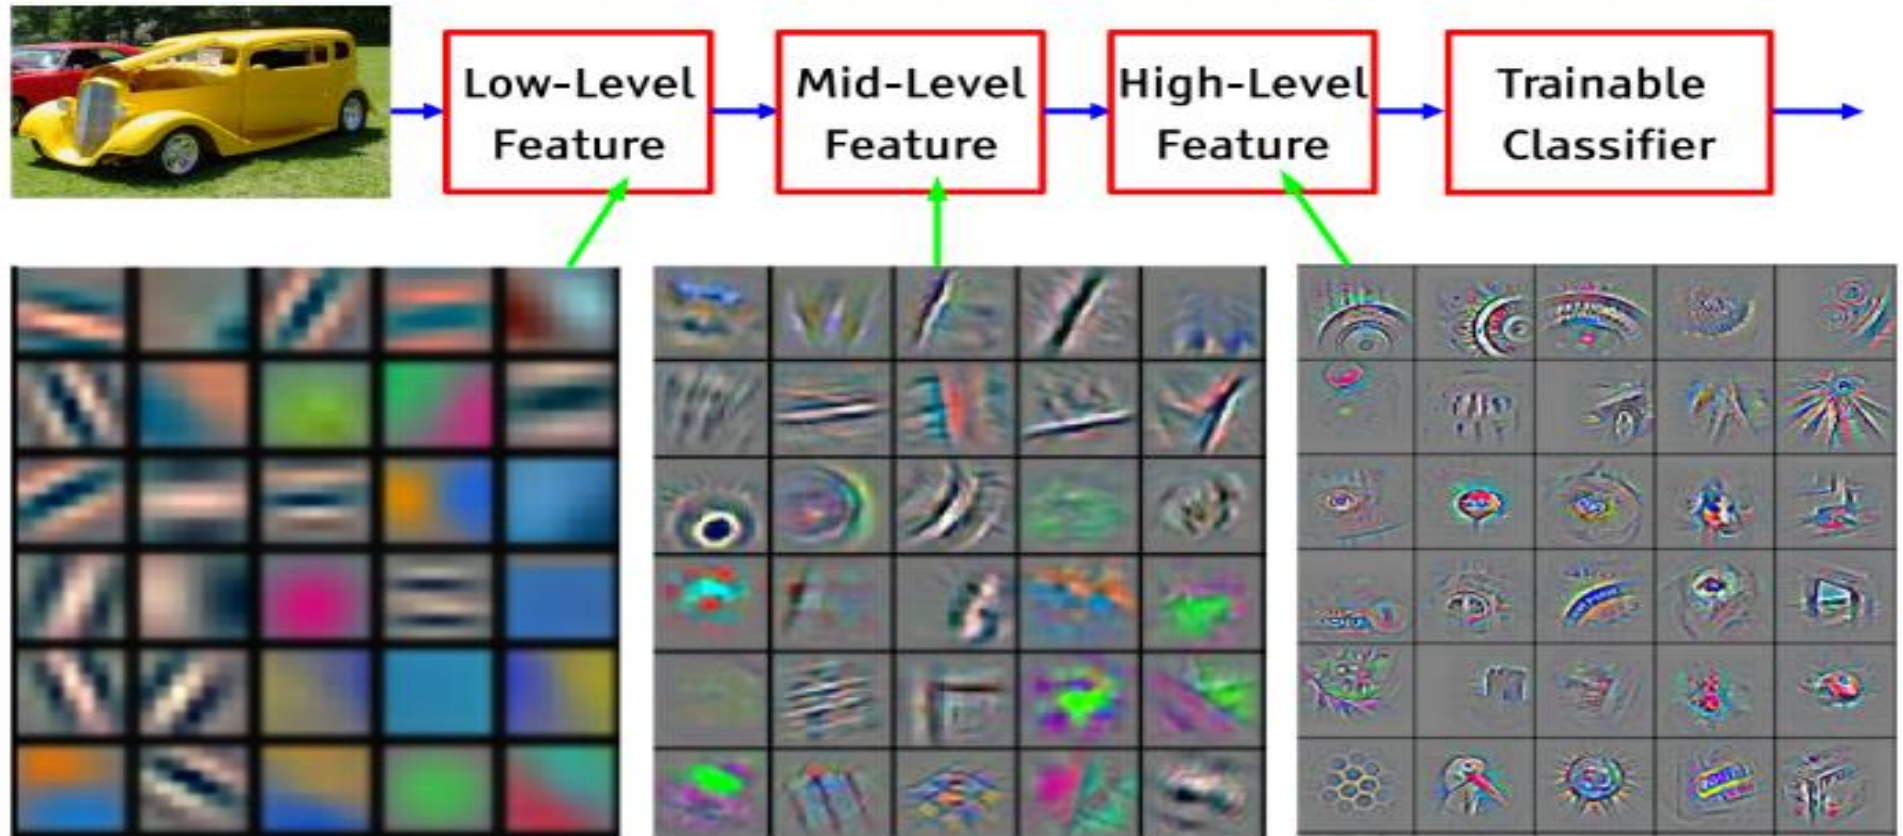
Deep Learning- CNN Convolutional Neural Networks

-



Deep Learning- CNN Convolutional Neural Networks



Hierarchical representation




Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

Deep Learning- CNN Convolutional Neural Networks


Convolution



No padding, stride 1



Padding 1, stride 1



No padding, stride 2

Deep Learning- CNN Convolutional Neural Networks


Convolution

•

$$\text{Output volume size} = N * ((W - K + 2P) / S + 1)$$

Convolution layer


32×32×3 image



If there are **four 5×5×3 filters**

Convolve (slide) over all spatial locations

4 separate activation maps




Deep Learning- CNN Convolutional Neural Networks

Convolution

- $$\text{Output volume size} = N * ((W - K + 2P) / S + 1)$$

Input size: 32*32, Kernel size: 5*5, padding=2, stride = 1

Output volume size = $(32 + 2 \times 2 - 5) / 1 + 1 = 32$ spatially
Each filter has $5 * 5 * 3 + 1$ (for bias) = 76 parameters
For all 10 filters \rightarrow 760 parameters





Deep Learning- CNN Convolutional Neural Networks

Convolution


•


$$\text{Output volume size} = N * ((W - K + 2P) / S + 1)$$






fewer parameters!





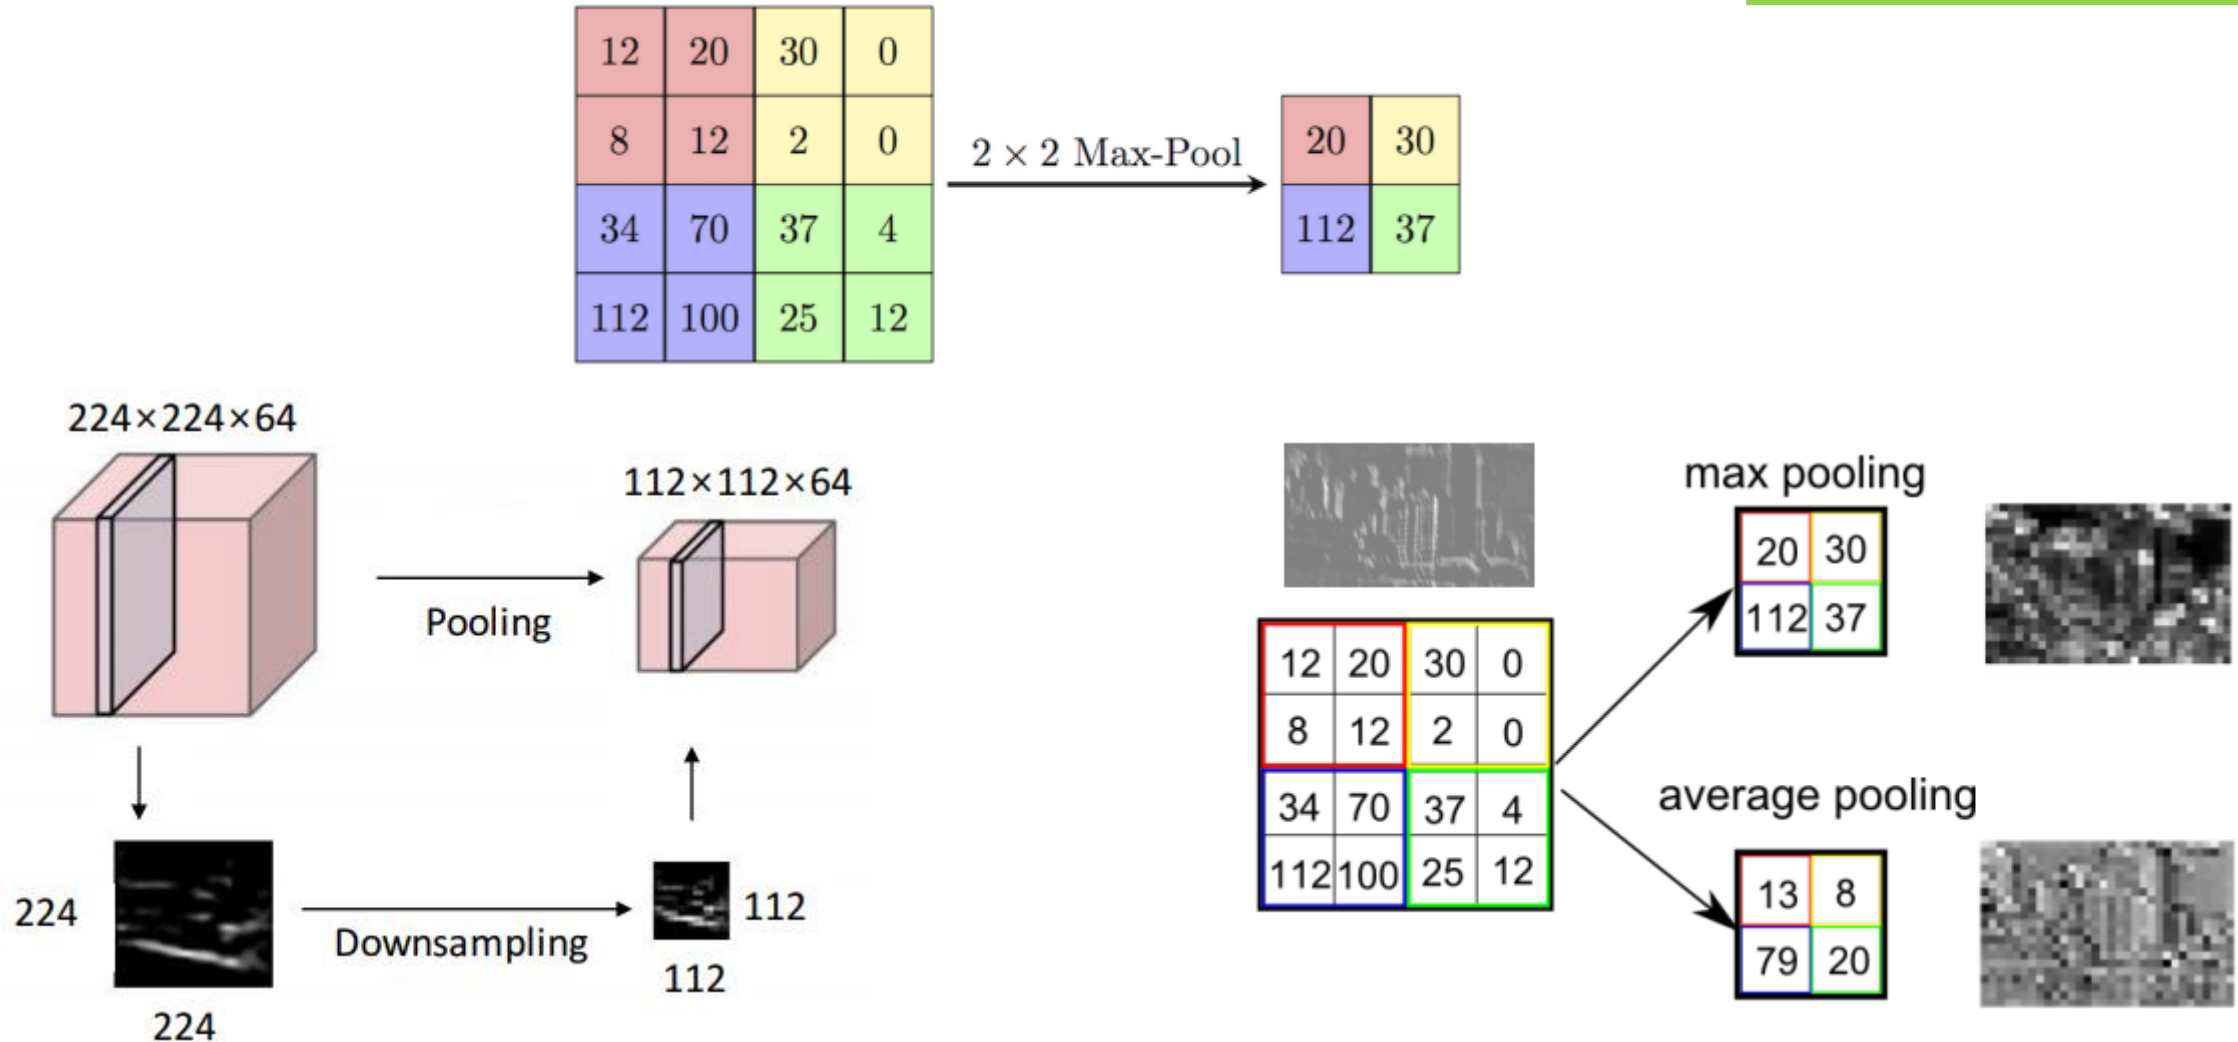
Fewer parameters

Even fewer parameters



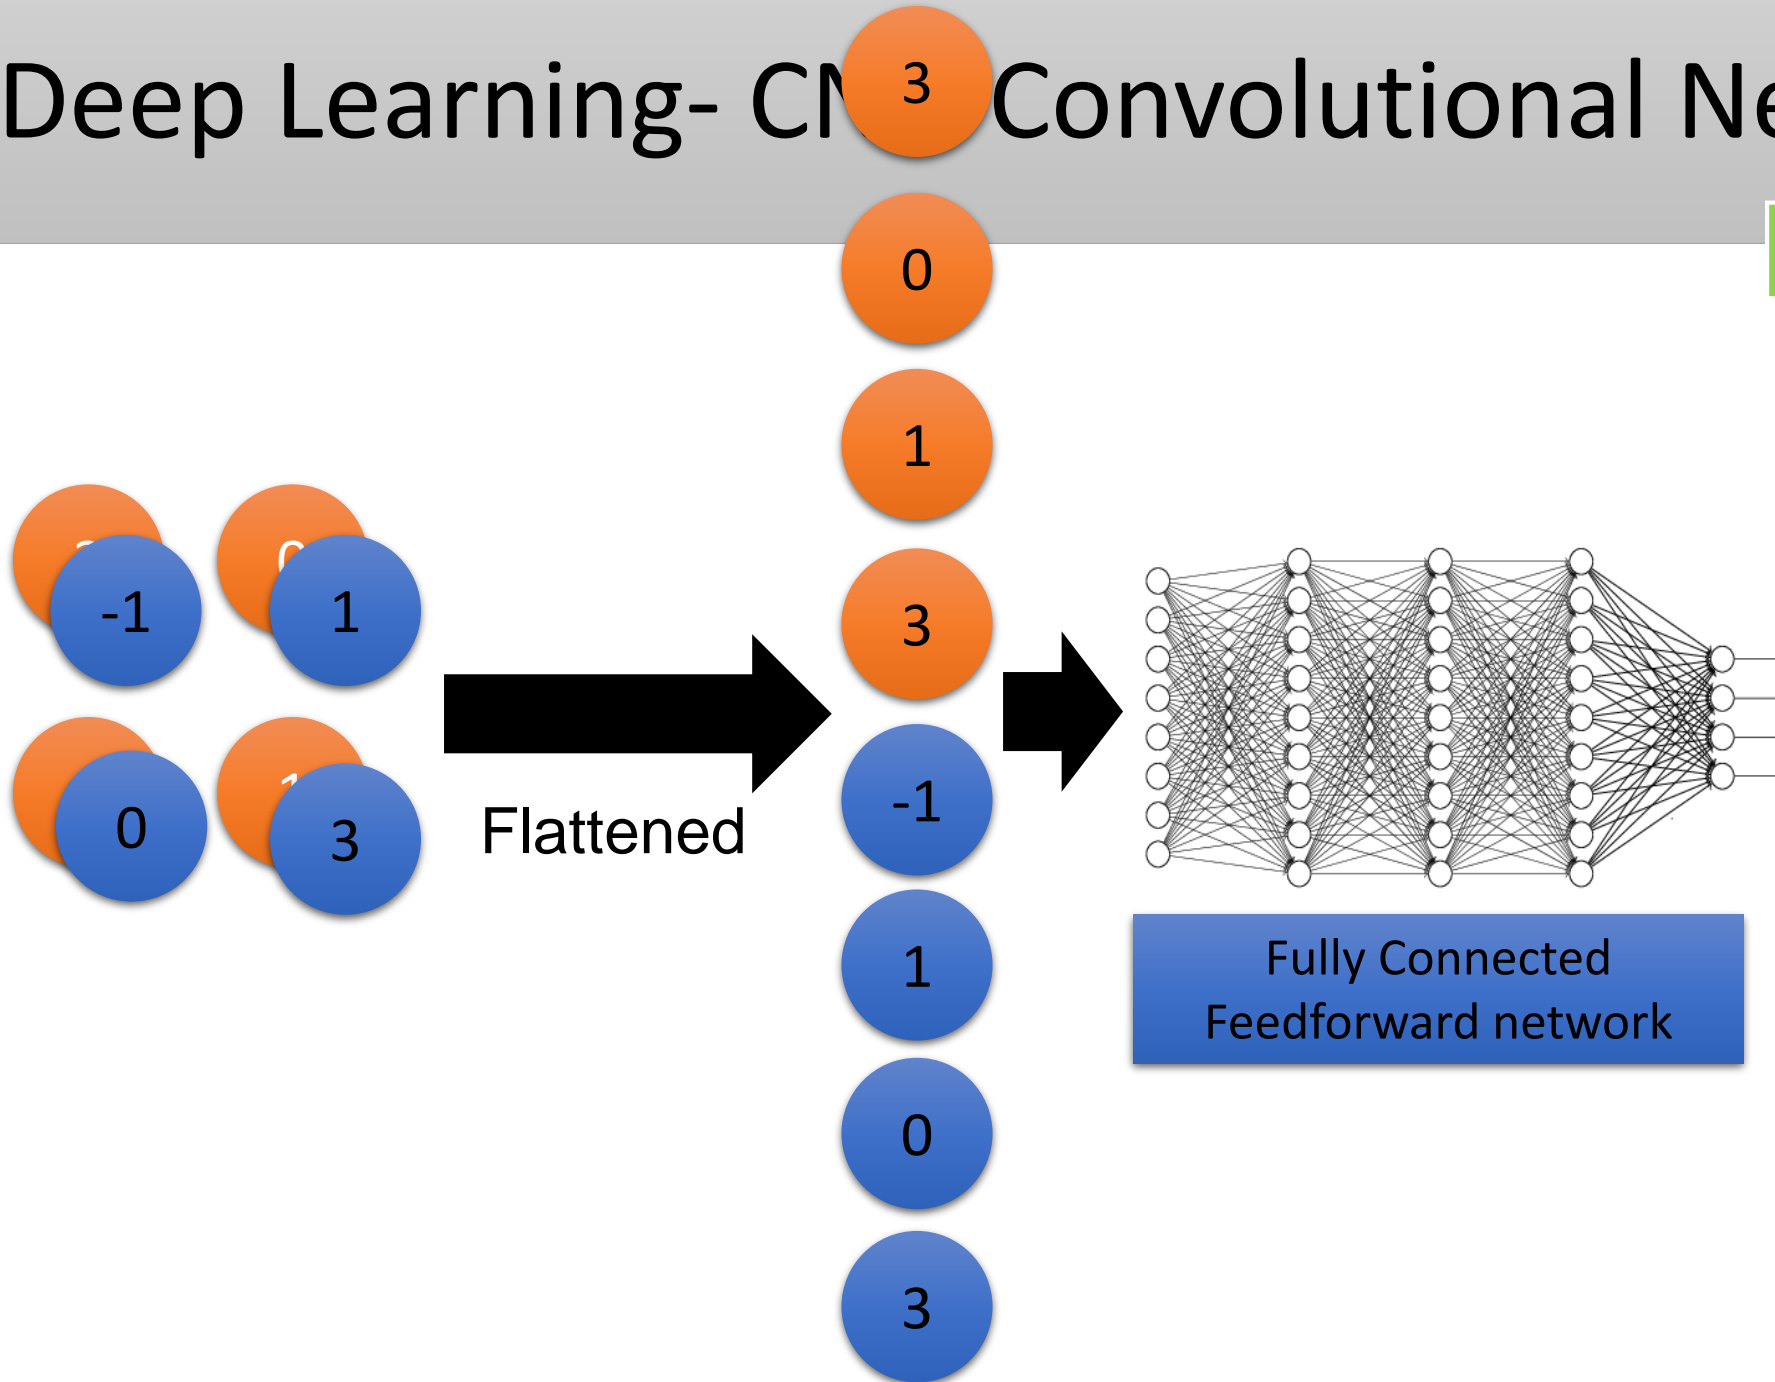
Deep Learning- CNN Convolutional Neural Networks

Pooling



Deep Learning- CNN Convolutional Neural Networks

Flattening and FC



The whole CNN- Cat dog classification example



Convolution

Max Pooling

Convolution


Max Pooling

Can
repeat
many
times

Flattened

cat dog

Fully Connected
Feedforward network



Deep Learning- CNN applications

•

Image Captioning

No errors

Minor errors

Somewhat related



A white teddy bear sitting in the grass



A man in a baseball uniform throwing a ball



A woman is holding a cat in her hand

Self-driving cars



Detection [Ren et al., 2015]

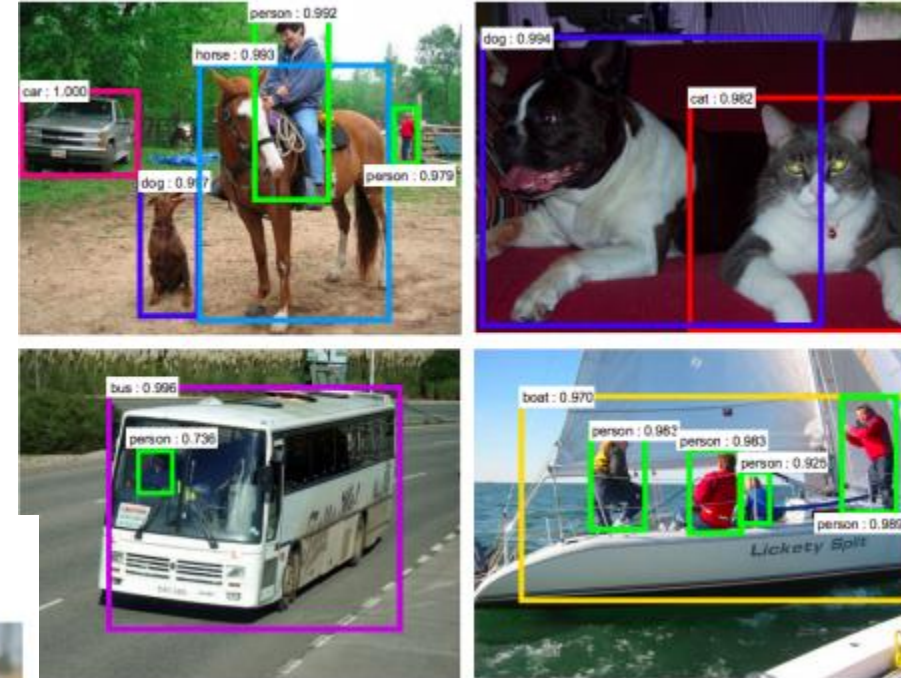


Image Recognition

Deep Learning- CNN applications

•

Image Captioning

No errors

Minor errors

Somewhat related



A white teddy bear sitting in the grass



A man in a baseball uniform throwing a ball



A woman is holding a cat in her hand

Self-driving cars



Detection [Ren et al., 2015]




Image Recognition

CNN-Keras

Python Implementation

```
import numpy as np # linear algebra
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
# read train
train = pd.read_csv("../input/train.csv")
print(train.shape)
train.head()
# put labels into y_train variable
Y_train = train["label"]
# Drop 'label' column
X_train = train.drop(labels = ["label"],axis = 1)
```

استيراد المكتبات اللازمة
Numpy للتعامل مع المصفوفات
Matplotlib للرسم والعرض
Pandas للتعامل مع ملفات مجموعات البيانات النصية مثل CSV data
Train_test_split لتقسيم مجموعة البيانات

قراءة مجموعة بيانات التدريب من
الملف train.csv

تحديد الخرج Y_train

تحديد الدخل X_train

Build & Train CNN

Simple Character Recognition Example

خطوة 1:
تحميل
مجموعة
بيانات الصور

ثم تقسيم
مجموعة
البيانات عند
الحاجة

CNN

Python Implementation

Build & Train CNN

Simple Character Recognition Example

خطوة 1:
تحميل
مجموعة
بيانات الصور

ثم تقسيم
مجموعة
البيانات عند
الحاجة

```
X_train = X_train / 255.0
```

```
print("x_train shape: ",X_train.shape)
```

تطبيع البيانات Normalize Data بتقسيم
قيم البيانات على 255

```
x_train shape: (42000, 784)
```

ناتج طباعة حجم مصفوفة X_train

```
X_train = X_train.values.reshape(-1,28,28,1)
```

```
print("x_train shape: ",X_train.shape)
```

تحويل مصفوفة X_train لحجم
مناسب للشبكة 1*28*28

```
x_train shape: (42000, 28, 28, 1)
```

ناتج طباعة حجم مصفوفة الدخل

```
from keras.utils.np_utils import to_categorical
```

```
Y_train = to_categorical(Y_train, num_classes = 10)
```

ترميز شعاع الخرج

2 ⇒ [0,0,1,0,0,0,0,0,0,0]

4 ⇒ [0,0,0,0,1,0,0,0,0,0]

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_val, Y_train, Y_val = train_test_split(X_train, Y_train, test_size = 0.1,  
random_state=2)
```

تقسيم مجموعة بيانات التدريب الأصلية إلى
تدريب بنسبة 90% وتحقق بنسبة 10%

CNN

Python Implementation

```
print("x_train shape",X_train.shape)
print("x_val shape",X_val.shape)
print("y_train shape",Y_train.shape)
print("y_val shape",Y_val.shape)
```


طباعة حجم كل من مجموعتي بيانات التدريب والتحقق

```
x_train shape (37800, 28, 28, 1)
x_test shape (4200, 28, 28, 1)
y_train shape (37800, 10)
y_test shape (4200, 10)
```

Some examples

```
plt.imshow(X_train[2][:,:,0],cmap='gray')
plt.show()
```

رسم (عرض) بعض عينات مجموعة البيانات



Build & Train CNN

Simple Character Recognition Example

خطوة 1:
تحميل
مجموعة
بيانات الصور

ثم تقسيم
مجموعة
البيانات عند
الحاجة

```

from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Conv2D, MaxPool2D
from keras.optimizers import RMSprop, Adam
from keras.preprocessing.image import ImageDataGenerator

```

Optimizer هو خوارزمية تستخدم لتقليل تابع الخطأ Loss Function لتعديل أوزان وانحيازات الشبكة

في حين تقوم خوارزمية التدريب Back Propagation باشتقاق ونشر الخطأ Gradient وحساب تعديلات الأوزان، يقوم Optimizer بتعديل الأوزان وفقاً لقاعدة محددة يستخدم فيها معدل التعلم لتعديل الأوزان مما يساعد الشبكة على التقارب بشكل أسرع

Optimizer الأكثر استخداماً لشبكات CNN هو ADAM

Build & Train CNN

Simple Character Recognition Example

مكتبة Keras للتعلم العميق:

Keras.sequential

لبناء طبقات شبكة التعلم العميق

Keras.optimizers

لاختيار نوع خوارزمية التحسين المستخدمة في عملية التدريب

Keras.preprocessing

image. لتطبيق عمليات المعالجة المسبقة على الصورة

خطوة

:2

استيراد
المكتبات
اللازمة

CNN

Python Implementation

```
model = Sequential()  
model.add(Conv2D(filters = 8, kernel_size = (5,5),padding = 'Same',  
                activation = 'relu', input_shape = (28,28,1)))
```

```
model.add(MaxPool2D(pool_size=(2,2)))
```

**طبقة Maxpooling
بحجم 2*2**

```
model.add(Dropout(0.25))
```

**طبقة dropout بنسبة
%25**

```
model.add(Conv2D(filters = 16, kernel_size = (3,3),padding = 'Same',  
                activation = 'relu'))
```

```
model.add(MaxPool2D(pool_size=(2,2), strides=(2,2)))  
model.add(Dropout(0.25))
```

**طبقة Maxpooling
بحجم 2*2**

**طبقة dropout بنسبة
%25**

```
# fully connected  
model.add(Flatten())  
model.add(Dense(256, activation = "relu"))  
model.add(Dropout(0.5))  
model.add(Dense(10, activation = "softmax"))
```

**الطبقة كاملة الاتصال:
طبقة Flatten وطبقة تخفيض وسيطية بحجم
256 عصبون وتابع Relu
طبقة Dropout بنسبة 50%
طبقة تخفيض تمثل طبقة التصنيف ب 10
عصبونات وتابع تفعيل Softmax**

**طبقة Conv2D عدد
المرشحات 8 وحجم
نافذة المرشح 5 ويتم
استخدام حشو وتابع
التفعيل Relu، حجم
صورة الدخل 28*28**

**طبقة Conv2D عدد
المرشحات 16 وحجم
نافذة المرشح 3 ويتم
استخدام حشو وتابع
التفعيل Relu**

Build & Train CNN

يتم إضافة طبقات للمودل
model باستخدام الأمر

model.add

**خطوة
3: بناء
طبقات
الشبكة**

CNN

Python Implementation

Build & Train CNN

Model.compile

خطوة 4:
تحديد
Optimizer

خطوة 5:
Compile
Model

خطوة 6:
تحديد بعض
بارامترات
التدريب

تحديد Optimizer وهو هنا
خوارزمية Adam بمعدل
تعلم 0.001 ومعاملات تدرج
beta1, beta2

مرحلة Compile Model
نحدد 3 أمور هي:
1- optimizer وهو هنا Adam
2- تابع Loss المستخدم في عملية التدريب وهو هنا
Categorical_Crossentropy لأن المسألة هنا تصنيف
متعدد الأصناف وليست Binary Classification وفي حال
كانت مسألة Binary Classification يستخدم تابع
Binary_Crossentropy
3- والمقياس المستخدم لتقييم الأداء وهو الدقة Accuracy
ويمكن اختيار Loss

عدد التكرارات
حجم Batch Size
وهو يمثل عدد عينات التدريب التي ستقدم للنموذج (المودل) كل دفعة تدريب
وهنا مثلاً 250.
بفرض عدد العينات 1000 سنحتاج $1000/250 = 4$ سيستغرق GPU 4
دفعات ليتم عملية تدريب واحدة.

Define the optimizer

```
optimizer = Adam(lr=0.001, beta_1=0.9, beta_2=0.999)
```

Compile the model

```
model.compile(optimizer = optimizer , loss =  
"categorical_crossentropy", metrics=["accuracy"])
```

epochs = 10 # for better result increase the epochs

```
batch_size = 250
```

CNN

Python Implementation

```
datagen = ImageDataGenerator(  
    rotation_range=5,  
    zoom_range = 0.1,  
    width_shift_range=0.1,  
    height_shift_range=0.1,  
    horizontal_flip=False,  
    vertical_flip=False)  
datagen.fit(X_train)
```

مجال التدوير العشوائي
المستخدم 5 درجات.

مجال ال Zoom هو 0.1
مجال الإزاحة الأفقية
والعمودية 0.1

إمكانية القلب الأفقي
والعمودي False (يمكن
وضعها True) لكن في مثال
الأرقام قد تؤثر على الرقم.



يمكن استخدام عمليات أخرى
مثل تغيير الإضاءة.

نستخدم
ImageDataGenerator

لتوليد عينات جديدة
(عشوائياً) من عينات
مجموعة البيانات
يمكن استخدام عملية واحدة
أو أكثر.



Data Augmentation



Build & Train CNN

تستخدم هذه الخطوة لتجنب
Overfitting ولزيادة عدد
عينات مجموعة التدريب
وتوليد عينات جديدة
بخصائص جديدة مما يزيد
قوة التدريب

خطوة 7:
Data
Augmenta
tion

Fit the model

```
history = model.fit_generator(datagen.flow(X_train,Y_train,
batch_size=batch_size),
epochs = epochs, validation_data =
(X_val,Y_val), steps_per_epoch=X_train.shape[0] //
batch_size)
```

نمرر لتابع التدريب

1- عينات التدريب X_{train}
وخرج كل عينة Y_{train} بعد
تمريرها على تابع $datagen$

2- حجم الدفعة Batch Size

3- عدد التكرارات

4- مجموعة بيانات التحقق
وهي X_{val}, Y_{val}

5- عدد العينات في كل تكرار
وهو ناتج قسمة عدد العينات
على حجم الدفعة.

Build & Train CNN

تستخدم هذه الخطوة لتجنب
Overfitting ولزيادة عدد
عينات مجموعة التدريب
وتوليد عينات جديدة
بخصائص جديدة مما يزيد
قوة التدريب

خطوة 8:
تدريب النموذج

Model Fit

CNN

Python Implementation

نتيجة التدريب

Build & Train CNN

$$37800/250 = 151.2 \approx 151$$

Epoch 1/10
151/151 [=====] - 26s 170ms/step - loss: 1.1310 - acc: 0.6186 - val_loss: 0.2363 - val_acc: 0.9386
Epoch 2/10
151/151 [=====] - 24s 160ms/step - loss: 0.4386 - acc: 0.8604 - val_loss: 0.1476 - val_acc: 0.9590
Epoch 3/10
151/151 [=====] - 24s 162ms/step - loss: 0.3276 - acc: 0.8960 - val_loss: 0.1146 - val_acc: 0.9674
Epoch 4/10
151/151 [=====] - 24s 160ms/step - loss: 0.2716 - acc: 0.9144 - val_loss: 0.1002 - val_acc: 0.9705
Epoch 5/10
151/151 [=====] - 24s 162ms/step - loss: 0.2458 - acc: 0.9228 - val_loss: 0.0858 - val_acc: 0.9750
Epoch 6/10
151/151 [=====] - 25s 163ms/step - loss: 0.2242 - acc: 0.9315 - val_loss: 0.0804 - val_acc: 0.9762
Epoch 7/10
151/151 [=====] - 24s 158ms/step - loss: 0.2076 - acc: 0.9361 - val_loss: 0.0733 - val_acc: 0.9781
Epoch 8/10
151/151 [=====] - 25s 164ms/step - loss: 0.1981 - acc: 0.9387 - val_loss: 0.0705 - val_acc: 0.9781
Epoch 9/10
151/151 [=====] - 24s 161ms/step - loss: 0.1886 - acc: 0.9423 - val_loss: 0.0647 - val_acc: 0.9817
Epoch 10/10
151/151 [=====] - 25s 163ms/step - loss: 0.1713 - acc: 0.9462 - val_loss: 0.0594 - val_acc: 0.9836

CNN

Python Implementation



Build & Train CNN

خطوة 9:
رسم منحنى
الأداء (الدقة
والـ LOSS)

لتقييم أداء النموذج يتم رسم
منحنى الأداء ويمكن استخدام
مصفوفة الـ Confusion
Matrix ومعاملات قياس
الأداء أيضاً.

نستخدم تعليمة الرسم history
التدريب للشبكة لعرض نتيجة
Val Loss
Val Accuracy

```
# Plot the loss and accuracy curves for training and validation  
plt.plot(history.history['val_loss'], color='b', label="validation  
loss")  
plt.title("Test Loss")  
plt.xlabel("Number of Epochs")  
plt.ylabel("Loss")  
plt.legend()  
plt.show()
```



```
# confusion matrix
import seaborn as sns

# Predict the values from the validation dataset
Y_pred = model.predict(X_val)
```

ترسم مصفوفة ال CM العلاقة بين
True Classes و Predicted classes
أجل معرفة تفاصيل نتائج كل صنف لوحده
ومعرفة الخلل في أي صنف في حال وجوده

Build & Train CNN

خطوة 9: رسم منحنى
الأداء (الدقة والـ LOSS)

```
# Convert predictions classes to one hot vectors
```

```
Y_pred_classes = np.argmax(Y_pred,axis = 1)
```

```
# Convert validation observations to one hot vectors
```

```
Y_true = np.argmax(Y_val,axis = 1)
```

```
# compute the confusion matrix
```

```
confusion_mtx = confusion_matrix(Y_true, Y_pred_classes)
```

```
# plot the confusion matrix
```

```
f,ax = plt.subplots(figsize=(8, 8))
```


```
sns.heatmap(confusion_mtx,annot=True,  
linewidths=0.01,cmap="Greens",linecolor="gray",fmt=  
'%.1f',ax=ax)
```

```
plt.xlabel("Predicted Label")
```

```
plt.ylabel("True Label")
```

```
plt.title("Confusion Matrix")
```

```
plt.show()
```




لتقييم أداء النموذج
يتم رسم منحنى
الأداء ويمكن
استخدام مصفوفة الـ
Confusion
Matrix ومعاملات
قياس الأداء أيضاً.

Build & Train CNN

خطوة 9: رسم منحنى
الأداء (الدقة والـ LOSS)

		PREDICTED	
		POSITIVE	NEGATIVE
ACTUAL	POSITIVE	TRUE POSITIVES	FALSE NEGATIVES
	NEGATIVE	FALSE POSITIVES	TRUE NEGATIVES



من خلال مصفوفة CM
نستطيع حساب
بارامترات

True Positives TP

True Negatives TN

False Positives FP

False Negatives FN

CNN

Python Implementation

Build & Train CNN

```
from sklearn.metrics import classification_report  
classification_report(Y_true, Y_pred_classes)
```



	precision	recall	f1-score	support
--	-----------	--------	----------	---------

0	0.99	1.00	0.99	411
1	1.00	0.98	0.99	485
2	0.98	0.99	0.98	403
3	0.99	0.98	0.98	418
4	0.99	0.97	0.98	461
5	0.99	0.98	0.98	372
6	0.98	0.99	0.99	413
7	0.98	0.99	0.99	446
8	0.97	0.99	0.98	382
9	0.97	0.97	0.97	409

accuracy			0.98	4200
macro avg	0.98	0.98	0.98	4200
weighted avg	0.98	0.98	0.98	4200

Precision= TP/ (TP+FP)

Recall = TP/(TP+FN)

F1-Score = 2*Precision*Recall/(Precision+Recall)

ACC= (TP+TN)/ (TP+TN+FP+FN)

الدقة أو مقياس الجودة

قابلية الإرجاع

الدقة الوسطية

مفهوم الدقة الشامل

يستخدم لتقييم أداء النموذج حيث يتم

حساب قيم

Precision, Recall, F1-score

لكل صنف من أصناف المسألة

ثم يتم حساب الدقة الوسطية